Overfitting-Underfitting - rev 2

Paulo Vieira

Agenda

Algoritmo meta-Treino (tensorflow)

Overfitting

Underfitting

Algoritmo meta-treino (tensorflow)

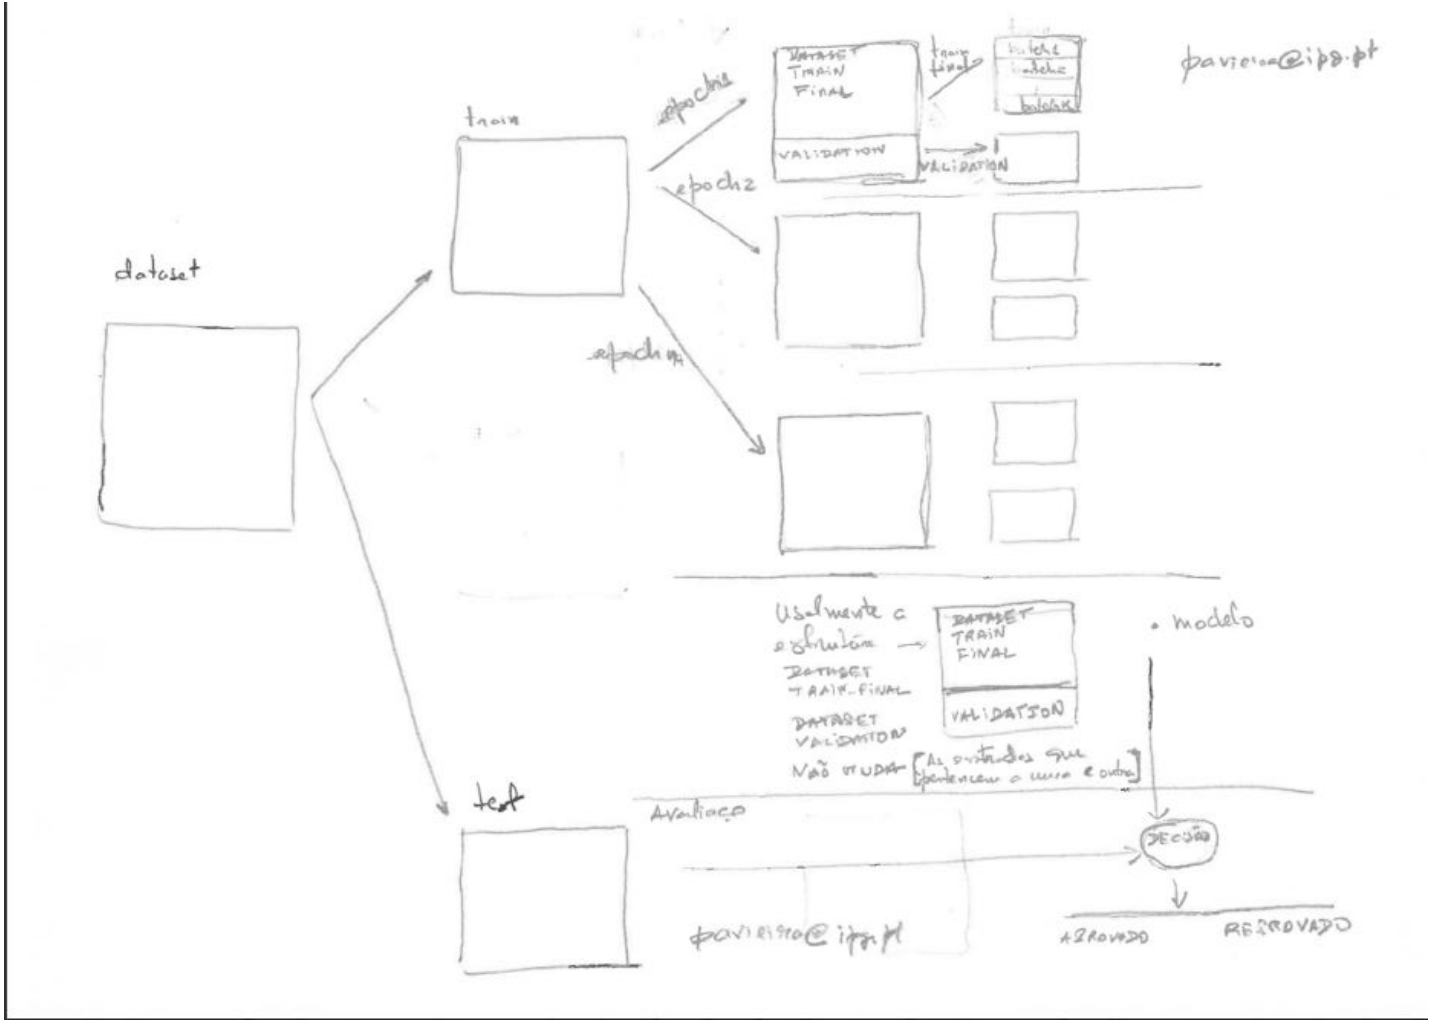

Overfitting

O que é Overfitting

Overfitting acontece quando o modelo:

> Aprende **demasiado bem os dados de treino**, mas falha em dados novos

Intuição simples

- O modelo **não aprende o padrão geral**
- Ele **decora os exemplos**

Forma correta de pensar

Durante o treino tens isto:

- Loss treino (por época)
- Loss validação (por época)

O overfitting aparece quando:

Treino continua a melhorar
Validação começa a piorar

Overfitting = boa performance no treino + má generalização

Overfitting

Técnica importante: Early Stopping

Para lidar com isso, usamos:

Early Stopping

- Para o treino automaticamente quando a validação começa a piorar
- Evita que o modelo “decore” demais

Exemplo:

- Melhor loss de validação na época i
- Depois piora
  você para na i (ou algumas épocas depois, com *patience*)

on_epoch_end Usa por defeito

```python
from tensorflow.keras.callbacks import EarlyStopping

early_stop = EarlyStopping(
    monitor='val_loss',    # o que queres monitorizar
    patience=3,            # nº de épocas sem melhoria antes de parar
    restore_best_weights=True
)
```

```python
model.fit(
    X_train, y_train,
    validation_data=(X_val, y_val),
    epochs=50,
    callbacks=[early_stop]
)
```

Quando são chamados?

Os callbacks podem ser executados em momentos como:

- início do treino
- fim de cada época
- fim de cada batch

Callbacks são:
Funções/objetos que o TensorFlow executa automaticamente **durante o treino**

Quem define **quando é chamado** o early_stop é o callback

Overfitting

Casos COM overfitting

Caso 1 — Overfitting clássico (loss)

Época	Loss treino	Loss validação
1	0.95	1.00
2	0.70	0.80
3	0.50	0.65
4	0.35	0.75 ❌
5	0.20	0.90 ❌

Sinal: validação começa a piorar a partir da época 4

Caso 2 — Overfitting com accuracy

Época	Accuracy treino	Accuracy validação
1	60%	58%
2	72%	68%
3	85%	72%
4	93%	70% ❌
5	99%	67% ❌

Sinal: treino sobe muito, validação cai

Overfitting

Casos SEM overfitting

Caso 3 — Treino saudável

Época	Loss treino	Loss validação
1	0.95	1.00
2	0.75	0.82
3	0.55	0.60
4	0.40	0.45
5	0.30	0.35 ✅

Sinal: ambos melhoram de forma consistente

Caso 4 — Underfitting (outro problema)

Época	Loss treino	Loss validação
1	1.2	1.3
5	1.0	1.1
10	0.9	1.0

Interpretação:

- Ambos continuam altos
- Modelo não aprende bem

Não é overfitting — é underfitting

Underfitting

O **underfitting** é um conceito de **aprendizagem automática (machine learning)** — e aparece tanto em **treino** como em **teste**, mas é principalmente um **problema do treino**

Como reconhecer?

- Erro **alto no treino**
- Erro **alto no teste**
- Modelo parece “burro” ou pouco ajustado

O que é underfitting?

É quando o modelo é **demasiado simples** e:

- **não aprende bem os padrões dos dados**
- comete muitos erros **até no treino**

Ou seja: *não consegue “captar” a realidade dos dados*

Treino vs Teste

- **Treino:** É onde o problema aparece
  → o modelo já falha aqui
- **Teste:** Também falha
  → porque nunca aprendeu bem

Exemplos de Underfitting

Caso 1 — Underfitting clássico (loss alta)

Época	Loss treino	Loss validação
1	1.30	1.35
2	1.25	1.30
3	1.20	1.28
4	1.15	1.25
5	1.10	1.22

Sinal:

- Ambos altos
- Melhoram muito pouco

Modelo não consegue aprender bem

Caso 2 — Underfitting com accuracy baixa

Época	Accuracy treino	Accuracy validação
1	50%	48%
2	55%	52%
3	58%	54%
4	60%	55%
5	62%	57%

Sinal:

- Accuracy baixa nos dois
- Evolução fraca

Modelo demasiado simples ou mal treinado

Exemplos sem Underfitting

Casos SEM underfitting (modelos bons)

Caso 3 — Bom treino (loss)

Época	Loss treino	Loss validação
1	1.00	1.05
2	0.70	0.75
3	0.50	0.55
4	0.35	0.40
5	0.25	0.30 ✅

Sinal:

- Valores descem bem
- Gap pequeno

Modelo aprende corretamente

Caso 4 — Bom treino (accuracy)

Época	Accuracy treino	Accuracy validação
1	60%	58%
2	72%	70%
3	82%	80%
4	88%	86%
5	92%	90% ✅

Sinal:

- Ambos sobem juntos
- Diferença pequena

Boa generalização

FIM